RESEARCH ARTICLE

Analisis Sentimen Publik terhadap Kontroversi Isu Ijazah Jokowi di Twitter/X Menggunakan Naive Bayes

MUHAMMAD ARIEFSYAH
NIM: 2411502194
Program Studi Teknik Informatika, Universitas Budi Luhur
Corresponding author: Muhammad Ariefsyah

ABSTRACT - Penelitian ini menganalisis sentimen publik terhadap kontroversi isu ijazah Jokowi di Twitter/X menggunakan leksikon KSI dan algoritma Naive Bayes. Data penelitian mengikuti urutan pemrosesan pada notebook: 1.000 tweet mentah dibaca dari dataset crawling, kemudian melalui basic cleaning, normalisasi slang, dan filter spam hingga diperoleh 979 tweet bersih. Analisis pendahuluan dilakukan terhadap 200 data: 199 tweet relevan terhadap topik dan 198 tweet berasal dari akun individu. Analisis entropy dan sebaran term dilakukan terhadap 200 data dengan total 3.608 kata dan 1.366 unique term. Output coding menghasilkan nilai entropy total -2,628284 karena rumus menghitung p log10(p); secara konvensional nilai Shannon entropy dibaca sebagai 2,628284 setelah diberi tanda negatif. Term paling dominan adalah "ijazah" (274), "jokowi" (237), dan "palsu" (235), yang menunjukkan fokus diskursus pada inti isu. Pelabelan manual dilakukan terhadap 350 data dengan distribusi 314 Negatif, 25 Netral, dan 11 Positif. Leksikon KSI berisi 9.071 kata dalam dictionary dan diterapkan pada 979 tweet, menghasilkan 872 Negatif, 55 Positif, dan 52 Netral. Perbandingan KSI dengan manual label pada 350 data menunjukkan akurasi 82,29%, tetapi KSI gagal mengenali kelas Positif. Pada tahap supervised learning, 350 data berlabel dibagi menjadi 245 training dan 105 testing, kemudian direpresentasikan menggunakan TF-IDF n-gram (1,2). Naive Bayes memperoleh accuracy 89,52%, tetapi confusion matrix menunjukkan seluruh data testing diprediksi sebagai Negatif. Temuan ini memperlihatkan bahwa accuracy tinggi dipengaruhi ketidakseimbangan kelas, sehingga interpretasi harus melibatkan precision, recall, f1-score, confusion matrix, serta analisis false positive dan false negative.

INDEX TERMS - analisis sentimen, Twitter/X, isu ijazah Jokowi, ijazah palsu, Naive Bayes, TF-IDF, KSI, entropy, opini publik digital, NLP.

I. PENDAHULUAN

Isu ijazah Jokowi merupakan salah satu diskursus politik digital yang berkembang di Twitter/X. Percakapan mengenai topik ini tidak hanya menyentuh isu dokumen administratif, tetapi juga berkelindan dengan legitimasi politik, kepercayaan publik, polarisasi opini, dan strategi narasi di ruang digital. Pengguna Twitter/X merespons isu ini dalam bentuk tuduhan, bantahan, sindiran, pembelaan, dan komentar emosional. Karena itu, topik ini layak dianalisis sebagai fenomena opini publik digital, bukan semata-mata sebagai isu administratif.

Twitter/X menyediakan data opini yang cepat, spontan, dan terbuka. Namun, data dari platform ini memiliki karakter yang tidak rapi: teks pendek, banyak mention, URL, slang, singkatan, emotikon, ironi, sarkasme, serta kata-kata politik yang konteksnya tidak selalu eksplisit. Kondisi tersebut membuat analisis manual terhadap seluruh data sulit dilakukan, sementara pendekatan komputasional perlu dirancang hati-hati agar tidak hanya membaca kata, tetapi juga memahami keterbatasan model.

Penelitian ini menggunakan analisis sentimen untuk membaca polaritas opini publik terhadap isu ijazah Jokowi. Sentimen dalam penelitian ini dibagi menjadi tiga kelas: Positif, Negatif, dan Netral. Kelas Negatif menunjukkan kritik, tuduhan, sindiran, atau ketidakpercayaan. Kelas Netral menunjukkan informasi, kutipan, atau pernyataan deskriptif. Kelas Positif menunjukkan dukungan, pembelaan, atau bantahan terhadap tuduhan. Penting ditegaskan bahwa analisis sentimen tidak membuktikan benar atau salahnya isu, melainkan mengukur kecenderungan ekspresi opini pada dataset.

Penelitian mengikuti workflow coding secara bertahap: load dataset, ambil kolom utama, cleaning, normalisasi slang, filter spam, preliminary analysis, perhitungan entropy, pelabelan manual, validasi KSI, ekstraksi fitur TF-IDF, pemodelan Naive Bayes, evaluasi model, confusion matrix, serta analisis false positive dan false negative. Dengan demikian, narasi artikel ini tidak berdiri terpisah dari coding, tetapi menjelaskan setiap output yang muncul di notebook dan file Excel.

II. TINJAUAN PUSTAKA

A. Analisis Sentimen pada Opini Publik Digital

Analisis sentimen atau opinion mining merupakan proses komputasional untuk mengidentifikasi polaritas opini dalam teks. Pada konteks media sosial, analisis sentimen sering digunakan untuk membaca respons publik terhadap tokoh, kebijakan, peristiwa politik, atau isu sosial. Keunggulannya terletak pada kemampuan memproses banyak data dalam waktu relatif singkat. Kelemahannya, model sering kesulitan membaca konteks, sarkasme, dan bias kelas jika distribusi label tidak seimbang.

Dalam isu politik, analisis sentimen harus dibaca dengan lapisan skeptis. Tweet bernada negatif tidak otomatis berarti klaim dalam tweet benar. Sebaliknya, tweet positif juga tidak otomatis membantah substansi isu. Analisis sentimen hanya menunjukkan cara publik mengekspresikan posisi, emosi, atau penilaian. Oleh karena itu, artikel ini membedakan antara polaritas opini dan validitas fakta.

B. Leksikon KSI dan Keterbatasannya

Pendekatan leksikon menggunakan kamus kata yang memiliki bobot polaritas. Dalam penelitian ini, leksikon KSI digunakan sebagai baseline untuk membandingkan hasil pelabelan otomatis dengan manual label. KSI bermanfaat karena dapat memberikan label tanpa training model. Namun, pendekatan ini cenderung mekanis karena bergantung pada kecocokan kata. Pada diskursus politik, satu kata dapat berubah makna ketika muncul dalam sindiran, negasi, atau konteks pertentangan narasi.

Misalnya, kata "asli" dapat bernilai positif jika digunakan sebagai pembelaan, tetapi dapat menjadi netral atau bahkan sarkastik jika muncul dalam frasa "asli tapi palsu". KSI berpotensi membaca kata positif secara terpisah tanpa memahami hubungan antar kata. Karena itu, KSI tidak diposisikan sebagai ground truth, melainkan sebagai pembanding leksikon.

C. Naive Bayes untuk Klasifikasi Teks

Naive Bayes merupakan algoritma probabilistik yang menghitung peluang suatu dokumen masuk ke kelas tertentu berdasarkan fitur kata. Pada klasifikasi teks, varian Multinomial Naive Bayes umum digunakan karena sesuai dengan representasi bag-of-words atau TF-IDF. Model ini cepat, sederhana, dan cocok sebagai baseline penelitian NLP. Namun, model dapat bias terhadap kelas mayoritas ketika distribusi label tidak seimbang.

$$P(c|d) \text{ proportional to } P(c) \times \text{product_i } P(t_i|c)$$

Dalam praktik komputasi, perkalian probabilitas kecil biasanya dihitung dalam bentuk log agar stabil secara numerik. Dengan representasi TF-IDF, kontribusi fitur dihitung sebagai bobot fitur dikalikan log probabilitas fitur pada kelas tertentu. Formula inilah yang digunakan untuk menjelaskan perhitungan manual algoritma pada bagian metodologi.

D. TF-IDF dan N-gram

TF-IDF mengubah teks menjadi fitur numerik berdasarkan frekuensi term dan kelangkaannya dalam korpus. Term yang sering muncul pada satu dokumen tetapi tidak terlalu umum di seluruh dokumen mendapat bobot relatif lebih tinggi. N-gram (1,2) digunakan agar model membaca unigram dan bigram. Pada isu ijazah Jokowi, bigram penting karena makna sering muncul dalam frasa seperti "ijazah palsu", "ijazah asli", atau "bukan palsu".

III. METODOLOGI PENELITIAN

A. Pengumpulan dan Pembacaan Dataset

Notebook memulai proses dengan membaca file dataset crawling Twitter/X bertopik ijazah palsu Jokowi. Dataset awal berjumlah 1.000 tweet dengan kolom seperti conversation_id_str, created_at, favorite_count, full_text, id_str, image_url, in_reply_to_screen_name, lang, location, quote_count, reply_count, retweet_count, tweet_url, user_id_str, dan username. Kolom full_text menjadi sumber utama teks, sedangkan username dan tweet_url disimpan untuk audit data.

TABLE I. Ringkasan pembacaan dataset awal

Tahap	Output coding	Interpretasi
Load dataset	1.000 rows	Data mentah hasil crawling Twitter/X
Kolom utama	full_text, username, tweet_url	Teks, identitas akun, dan sumber tweet
Topik	Ijazah palsu Jokowi	Diskursus politik digital terkait ijazah Jokowi

Tahap awal ini penting karena memastikan dataset yang dianalisis memiliki kolom yang konsisten. Apabila kolom utama tidak disiapkan sejak awal, proses cleaning, filtering, labeling, dan modeling berisiko menggunakan sumber teks yang salah. Dalam notebook, teks tweet disalin ke kolom Content atau Clean_Text untuk memudahkan proses berikutnya.

B. Basic Cleaning dan Normalisasi Slang

Basic cleaning dilakukan untuk menghapus elemen yang tidak diperlukan dalam analisis teks, seperti URL, mention, hashtag, karakter non-huruf, angka, dan spasi berlebih. Output notebook menunjukkan tidak ada baris yang hilang pada tahap ini: jumlah data tetap 1.000. Artinya, semua tweet masih memiliki teks setelah dibersihkan.

TABLE II. Perubahan jumlah data pada cleaning dan filter spam

Tahap	Sebelum	Sesudah	Rows removed
Basic cleaning	1.000	1.000	0
Filter spam	1.000	979	21

Setelah basic cleaning, notebook melakukan normalisasi slang. Kata seperti "gak", "ga", "nggak", "tdk", dan "tak" dinormalisasi menjadi "tidak". Kata seperti "yg" menjadi "yang", "gw" menjadi "saya", dan variasi informal lain diseragamkan. Tahap ini penting karena model machine learning membaca kata sebagai fitur. Jika kata bermakna sama ditulis berbeda, model akan menganggapnya fitur berbeda dan pola sentimen menjadi lebih sulit dipelajari.

Pada isu politik, normalisasi negasi sangat krusial. Kata "tidak" sering menjadi pembeda makna dalam kalimat, misalnya "tidak palsu", "tidak asli", atau "tidak percaya". Tanpa normalisasi, bentuk seperti "gak", "ga", dan "nggak" akan terpecah menjadi fitur berbeda sehingga mengurangi konsistensi representasi teks.

C. Filter Spam

Filter spam menggunakan daftar kata seperti lazada, shopee, tokopedia, promo, diskon, parfum, skincare, voucher, dan kata lain yang berpotensi menunjukkan konten promosi atau tidak relevan. Notebook menunjukkan 21 data teridentifikasi sebagai spam dan dihapus. Setelah filter spam, dataset utama berjumlah 979 tweet. Data inilah yang digunakan sebagai basis analisis KSI penuh dan pemilihan sampel untuk analisis lanjutan.

TABLE III. Output filter spam dari notebook

Kategori	Jumlah
Bukan spam	979
Spam	21
Total sebelum filter	1.000
Total setelah filter	979

Secara metodologis, filter spam diperlukan agar analisis tidak dipengaruhi konten promosi. Tanpa filter ini, term yang muncul dalam visualisasi bisa berasal dari iklan atau konten tidak relevan, bukan dari diskursus politik mengenai ijazah Jokowi.

D. Preliminary Analysis: Relevansi Topik

Notebook membuat file Excel untuk labeling relevansi topik terhadap 200 data pertama. Setelah file diisi manual, hasilnya menunjukkan 199 data Relevan dan 1 data Tidak Relevan. Dengan demikian, tingkat relevansi topik adalah 99,5%. Angka ini menunjukkan bahwa strategi crawling cukup fokus terhadap isu ijazah Jokowi.

TABLE IV. Hasil preliminary analysis relevansi topik

Label relevansi	Jumlah	Persentase
Relevan	199	99,5%
Tidak Relevan	1	0,5%
Total	200	100%

Interpretasi relevansi ini penting karena dataset Twitter/X sering mengandung noise. Dalam penelitian ini, noise topik sangat kecil pada sampel 200 data. Hal ini memperkuat validitas dataset sebagai bahan analisis opini publik terhadap isu ijazah Jokowi.

E. Preliminary Analysis: Komposisi Akun

File Excel komposisi akun menunjukkan 198 dari 200 tweet berasal dari akun individu, sedangkan 2 tweet berasal dari akun official/media resmi. Artinya, 99% percakapan pada sampel didominasi akun individu. Dominasi ini menunjukkan bahwa diskursus yang dianalisis lebih dekat dengan ekspresi publik digital daripada narasi institusional atau media.

TABLE V. Komposisi akun pada 200 sampel

Jenis akun	Jumlah	Persentase
Individu	198	99,0%
Official/Media Resmi	2	1,0%
Total	200	100%

Dominasi akun individu memiliki konsekuensi interpretatif. Tweet individu cenderung lebih emosional, menggunakan bahasa tidak formal, dan lebih bebas memuat sindiran atau tuduhan. Karena itu, hasil sentimen yang sangat negatif perlu dibaca sebagai ekspresi ruang publik digital yang intens, bukan sebagai representasi survei formal seluruh populasi.

F. Entropy dan Sebaran Term

Analisis entropy dilakukan pada 200 data. Output Excel menunjukkan jumlah record 200, total kata 3.608, unique term 1.366, dan entropy total -2,628284. Sheet term_entropy memuat kolom Term, Frekuensi (Ni), Total Kata (N), Ni/N, Log10(Ni/N), dan Nilai Entropy Term. Berdasarkan struktur kolom tersebut, coding menghitung nilai entropy term sebagai p x log10(p), sehingga hasil total bernilai negatif. Dalam rumus Shannon entropy konvensional, nilai entropy diberi tanda negatif: H = - sum p log(p).

p_i = Ni / N

Coding: E_i = p_i x log10(p_i), sehingga total = sum E_i = -2.628284

Shannon convention: H = -sum p_i x log10(p_i) = 2.628284

Dengan demikian, perbedaan antara entropy coding dan entropy manual bukan terletak pada data, melainkan pada tanda rumus. Coding menyimpan nilai p log10(p) yang bernilai negatif karena $0 < p < 1$. Secara manual, jika mengikuti definisi Shannon, nilai tersebut dikalikan -1 sehingga menjadi positif. Artikel ini mempertahankan angka output coding, tetapi menjelaskan bahwa pembacaan entropy konvensional adalah nilai absolutnya.

Contoh Perhitungan Manual Entropy Term

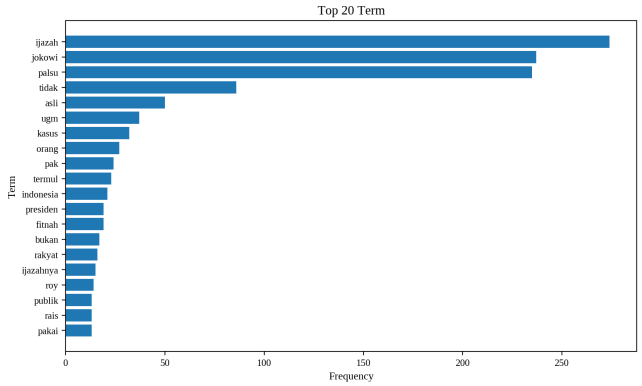
TABLE VI. Contoh perhitungan manual entropy term

Term	Ni	N	p=Ni/N	log10(p)	p log10(p)	-p log10(p)
ijazah	274	3608	0,075942	-1,119516	-0,085019	0,085019
jokowi	237	3608	0,065687	-1,182518	-0,077676	0,077676
palsu	235	3608	0,065133	-1,186199	-0,077261	0,077261
tidak	86	3608	0,023836	-1,622768	-0,038680	0,038680

Sebagai contoh, term "ijazah" muncul 274 kali dari total 3.608 kata, sehingga p = 274/3608 = 0,075942. Log10 dari probabilitas tersebut adalah -1,119516. Nilai coding untuk term ini adalah p x log10(p) = -0,085019. Jika menggunakan rumus Shannon, kontribusi entropy term menjadi 0,085019 setelah diberi tanda negatif. Prosedur yang sama berlaku untuk term "jokowi", "palsu", dan term lain.

Jika menggunakan unique term sebagai batas maksimum entropy, nilai entropy maksimum berbasis log10 adalah log10(1.366) = 3,13545. Dengan entropy konvensional 2,628284, normalized entropy dapat dihitung sebagai 2,628284 / 3,13545 = sekitar 0,838. Perhitungan ini menunjukkan bahwa meskipun beberapa kata sangat dominan, korpus

tetap memiliki variasi term yang cukup luas. Namun, karena notebook tidak menampilkan normalized entropy secara eksplisit, nilai ini diposisikan sebagai perhitungan turunan dari output yang tersedia, bukan output utama coding.



Gambar 1. Visualisasi Top 20 term dari output notebook.

Visualisasi Top 20 term memperlihatkan dominasi "ijazah", "jokowi", dan "palsu". Ketiga term ini membentuk inti diskursus. Kata "tidak" menunjukkan peran negasi, bantahan, atau kritik. Kata "asli" menjadi pasangan oposisi dari "palsu". Kata "ugm" menunjukkan bahwa institusi pendidikan menjadi rujukan penting dalam perdebatan. Dengan demikian, sebaran term mendukung kesimpulan bahwa dataset fokus pada perdebatan keaslian, tuduhan, dan legitimasi, bukan topik umum yang tidak relevan.

TABLE VII. Kelompok makna dari term dominan

Kelompok makna	Contoh term	Interpretasi
Objek isu	ijazah, jokowi, palsu	Percakapan berpusat pada inti kontroversi ijazah Jokowi.
Negasi dan bantahan	tidak, bukan, asli	Teks memuat penolakan, pembelaan, atau pembalikan klaim.
Rujukan institusional	ugm, presiden	Diskursus mengaitkan isu dengan lembaga pendidikan dan posisi politik.
Framing politik	rakyat, fitnah, kasus, roy	Percakapan bergerak ke opini politik, tuduhan, dan aktor publik.

G. Pelabelan Manual Sentimen

Pelabelan manual dilakukan terhadap 350 data. Label yang digunakan adalah Negatif, Netral, dan Positif. Output Excel menunjukkan 314 data berlabel Negatif, 25 Netral, dan 11 Positif. Distribusi ini sangat tidak seimbang: 89,7% data berada pada kelas Negatif. Kondisi ini sangat penting karena akan memengaruhi perilaku model Naive Bayes pada tahap klasifikasi.

TABLE VIII. Distribusi manual label sentimen

Label	Jumlah	Persentase	Makna operasional
Negatif	314	89,7%	Kritik, tuduhan, sindiran, kemarahan, atau ketidakpercayaan
Netral	25	7,1%	Informasi, kutipan, atau pernyataan deskriptif
Positif	11	3,1%	Pembelaan, dukungan, atau bantahan terhadap tuduhan
Total	350	100%	-

Dominasi Negatif menunjukkan bahwa percakapan publik dalam dataset cenderung kritis dan menyerang. Namun, hal ini tidak berarti penelitian membuktikan substansi tuduhan. Label Negatif hanya menunjukkan bahwa teks mengandung polaritas negatif terhadap isu, aktor, atau narasi yang dibahas. Pembedaan ini penting agar analisis sentimen tidak disalahartikan sebagai verifikasi fakta.

H. Leksikon KSI dan Label Otomatis

Notebook membaca dua file KSI: positive dan negative. Output menunjukkan 3.609 term positive dan 6.609 term negative. Setelah cleaning dan penggabungan, total term KSI menjadi 10.213. Namun setelah dibuat dictionary, jumlah kata unik yang digunakan sebagai kamus skor menjadi 9.071. Perbedaan jumlah ini wajar karena terdapat duplikasi atau kata yang sama muncul setelah proses cleaning.

TABLE IX. Ringkasan leksikon KSI

Komponen KSI	Jumlah
Term positive	3.609
Term negative	6.609
Total term setelah cleaning	10.213
Dictionary KSI unik	9.071

Fungsi labeling KSI bekerja dengan cara memecah teks menjadi token, mencocokkan setiap token ke dalam dictionary, menjumlahkan skor kata, lalu menentukan label berdasarkan total skor. Jika skor lebih besar dari nol, label menjadi Positif. Jika skor kurang dari nol, label menjadi Negatif. Jika skor sama dengan nol, label menjadi Netral.

KSI_Score(d) = sum score(token_i), for token_i in lexicon

if score > 0 -> Positif; if score < 0 -> Negatif; if score = 0 -> Netral

Label KSI diterapkan pada seluruh 979 tweet setelah filter spam. Output notebook menunjukkan distribusi: 872 Negatif, 55 Positif, dan 52 Netral. Hasil ini memperlihatkan bahwa leksikon juga membaca dominasi sentimen negatif, sejalan dengan manual label. Namun, validasi terhadap manual label tetap diperlukan karena leksikon tidak selalu mampu membaca konteks politik.

TABLE X. Distribusi label otomatis KSI pada 979 tweet

Label KSI	Jumlah pada 979 data	Persentase
Negatif	872	89,1%
Positif	55	5,6%
Netral	52	5,3%
Total	979	100%

IV. HASIL DAN PEMBAHASAN

A. Validasi Manual Label vs. KSI

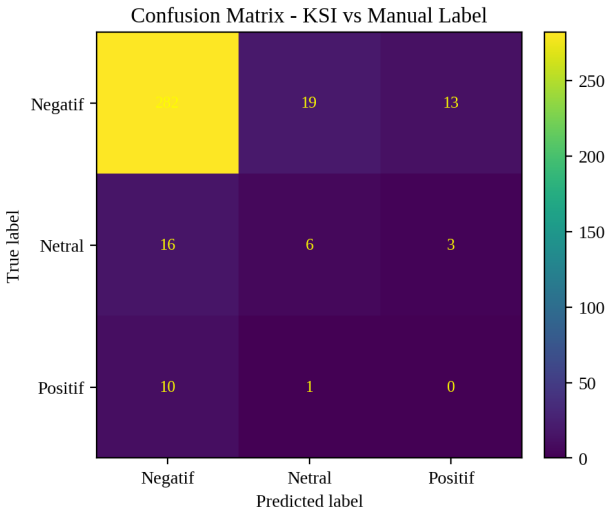
Perbandingan manual label dengan label KSI dilakukan hanya pada 350 data yang memiliki manual label. Output notebook menunjukkan akurasi KSI terhadap manual label sebesar 0,8229 atau 82,29%. Dari 350 data, 288 data memiliki label sama, sedangkan 62 data berbeda. Secara permukaan, akurasi 82,29% terlihat tinggi. Namun, classification report menunjukkan performa KSI tidak seimbang antar kelas.

TABLE XI. Ringkasan perbandingan label manual dan KSI

Metrik	Nilai
Jumlah data KSI penuh	979
Data manual yang dapat dibandingkan	350
Akurasi KSI terhadap manual label	82,29%
Label sama	288
Label berbeda	62
Persentase berbeda	17,71%

TABLE XII. Classification report KSI vs manual label

Kelas	Precision	Recall	F1-score	Support
Negatif	0,92	0,90	0,91	314
Netral	0,23	0,24	0,24	25
Positif	0,00	0,00	0,00	11
Accuracy	-	-	0,82	350
Macro avg	0,38	0,38	0,38	350
Weighted avg	0,84	0,82	0,83	350



Gambar 2. Confusion matrix KSI vs manual label dari output notebook.

KSI memiliki precision 0,92 dan recall 0,90 pada kelas Negatif. Artinya, KSI cukup kuat membaca teks yang secara manual memang negatif. Namun, kelas Netral hanya memperoleh f1-score 0,24 dan kelas Positif memperoleh 0,00. Kegagalan membaca kelas Positif menunjukkan bahwa pendekatan leksikon kurang stabil pada kelas minoritas, terutama dalam diskursus politik yang penuh konteks, sindiran, dan negasi.

Data audit label berbeda berjumlah 62. Contoh perbedaan memperlihatkan bahwa KSI dapat membaca kata tertentu secara literal tanpa memahami makna keseluruhan kalimat. Misalnya, kalimat yang mengandung kata "asli" dapat diberi skor positif, padahal secara manual konteksnya dapat netral atau menyindir. Sebaliknya, tweet positif yang membela atau membantah tuduhan dapat dibaca negatif karena mengandung kata seperti "diserang", "bukan", atau "isu" yang memiliki skor negatif dalam kamus.

B. Split Data dan TF-IDF

Setelah manual label dibersihkan, 350 data digunakan untuk supervised learning. Notebook membagi data dengan train_test_split, test_size 0,3, random_state 42, dan stratify berdasarkan label. Output menunjukkan 245 data training dan 105 data testing. Karena stratified split digunakan, proporsi label pada training dan testing tetap mengikuti distribusi keseluruhan.

TABLE XIII. Distribusi label pada train-test split

Set	Negatif	Netral	Positif	Total
Training	220	17	8	245
Testing	94	8	3	105
Total	314	25	11	350

Distribusi ini menunjukkan ketimpangan yang sangat kuat. Pada training set, kelas Negatif berjumlah 220, sedangkan Netral hanya 17 dan Positif hanya 8. Ini berarti model melihat jauh lebih banyak contoh Negatif selama training. Kondisi ini menjadi akar bias kelas mayoritas pada evaluasi Naive Bayes.

TF-IDF digunakan untuk mengubah teks menjadi vektor numerik. Notebook menggunakan max_features=5000 dan ngram_range=(1,2). Dengan konfigurasi ini, fitur dapat berupa kata tunggal maupun pasangan kata. Contoh fitur yang relevan secara semantik adalah "ijazah", "palsu", "ijazah palsu", "tidak asli", atau "bukan palsu". Fitur-fitur tersebut kemudian digunakan oleh Naive Bayes untuk menghitung probabilitas kelas.

TABLE XIV. Konfigurasi pemodelan

Komponen	Nilai
Data berlabel	350
Training	245
Testing	105
Feature extraction	TF-IDF
Max features	5.000
N-gram	(1,2)
Model	Naive Bayes

C. Perhitungan Manual Naive Bayes

Naive Bayes menghitung kelas dengan skor posterior terbesar. Secara manual, langkah pertama adalah menghitung prior setiap kelas dari data training. Berdasarkan split notebook, training set berisi 220 Negatif, 17 Netral, dan 8 Positif dari total 245 data. Dengan demikian prior kelas adalah sebagai berikut.

TABLE XV. Perhitungan prior kelas Naive Bayes

Kelas	Jumlah train	P(c)	log P(c)
Negatif	220	220/245 = 0,89796	-0,10763
Netral	17	17/245 = 0,06939	-2,66804
Positif	8	8/245 = 0,03265	-3,42182

Prior tersebut menjelaskan mengapa kelas Negatif sangat kuat sejak awal. Sebelum melihat fitur kata pun, peluang awal Negatif sudah jauh lebih besar dibanding Netral dan Positif. Dalam data yang sangat timpang, prior besar seperti ini dapat membuat model cenderung memilih kelas mayoritas jika fitur tidak cukup kuat membedakan kelas minoritas.

Langkah kedua adalah menghitung likelihood fitur terhadap kelas. Pada Multinomial Naive Bayes dengan smoothing, probabilitas fitur dapat dinyatakan sebagai berikut.

$$P(t|c) = (\text{weighted_count}(t,c) + \text{alpha}) / (\text{sum_weighted_features}(c) + \text{alpha x } V)$$

Karena notebook menggunakan TF-IDF, nilai fitur bukan sekadar hitungan kata mentah, melainkan bobot TF-IDF. Scikit-learn kemudian menggunakan bobot tersebut sebagai masukan untuk menghitung feature likelihood. Untuk prediksi, model menghitung skor log sebagai berikut.

$$\text{score}(c,d) = \log P(c) + \sum_i x_i(d) \times \log P(t_i|c)$$

Dokumen diklasifikasikan ke kelas dengan score terbesar. Perhitungan berikut menggunakan salah satu contoh data testing yang secara manual berlabel Netral tetapi diprediksi Negatif oleh model. Teks contoh: "pernah baca suami nya rektor ugm ada kasus ulang piutang langsung ijazah jokowi palsu menjadi asli kasus sudah selesai mirip eggi sudjana dan rismon". Fitur dengan bobot TF-IDF tertinggi antara lain "kasus", "ada kasus", "eggi", "eggi sudjana", "mirip", dan "rektor ugm".

TABLE XVI. Contoh kontribusi fitur pada perhitungan log-score Naive Bayes

Fitur	TF-IDF	Log-kontrib. Negatif	Log-kontrib. Netral	Log-kontrib. Positif
kasus	0,2883	-2,1344	-2,4264	-2,4111
ada kasus	0,2728	-2,3456	-2,3278	-2,3261
eggi	0,2728	-2,3505	-2,3278	-2,3261
eggi sudjana	0,2728	-2,3505	-2,3278	-2,3261
mirip	0,2728	-2,3412	-2,3278	-2,3261
rektor ugm	0,2538	-2,1386	-2,1654	-2,1638

TABLE XVII. Contoh hasil manual log-score Naive Bayes

Kelas	Log prior	Total log-score contoh dokumen	Prediksi
Negatif	-0,10763	-37,57353	Terbesar
Netral	-2,66804	-42,44373	-
Positif	-3,42182	-43,33933	-

Tabel XVI dan XVII memperlihatkan mekanisme model secara konkret. Meskipun contoh dokumen tersebut secara manual berlabel Netral, skor log untuk kelas Negatif adalah yang paling besar (-37,57353). Karena Naive Bayes memilih kelas dengan skor terbesar, dokumen tersebut diprediksi sebagai Negatif. Contoh ini menjelaskan mengapa kelas Netral mudah tertarik ke Negatif: prior Negatif sangat besar dan banyak fitur dalam diskursus politik lebih sering muncul pada data training Negatif.

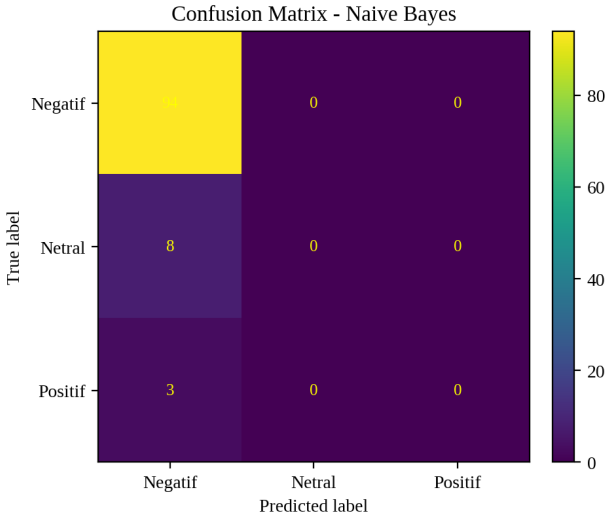
D. Evaluasi Model Naive Bayes

Output notebook menunjukkan accuracy Naive Bayes sebesar 0,895238 atau 89,52%. Namun, classification report menunjukkan masalah serius pada kelas Netral dan Positif. Kelas Negatif memiliki precision 0,90, recall 1,00, dan f1-score 0,94. Sebaliknya, Netral dan

Positif memiliki precision, recall, dan f1-score 0,00. Artinya, model tidak berhasil mengenali satu pun data Netral maupun Positif pada testing set.

TABLE XVIII. Classification report Naive Bayes

Kelas	Precision	Recall	F1-score	Support
Negatif	0,90	1,00	0,94	94
Netral	0,00	0,00	0,00	8
Positif	0,00	0,00	0,00	3
Accuracy	-	-	0,90	105
Macro avg	0,30	0,33	0,31	105
Weighted avg	0,80	0,90	0,85	105



Gambar 3. Confusion matrix Naive Bayes dari output notebook.

TABLE XIX. Confusion matrix Naive Bayes

True / Pred	Negatif	Netral	Positif
Negatif	94	0	0
Netral	8	0	0
Positif	3	0	0

Confusion matrix menunjukkan seluruh 105 data testing diprediksi sebagai Negatif. Sebanyak 94 data Negatif benar diprediksi Negatif, tetapi 8 data Netral dan 3 data Positif juga salah diprediksi Negatif. Tidak ada satupun prediksi Netral maupun Positif. Dengan demikian, accuracy tinggi tidak mencerminkan kemampuan model membaca tiga kelas secara seimbang. Accuracy menjadi tinggi karena 94 dari 105 data testing memang Negatif.

E. Analisis False Positive dan False Negative

Analisis false positive dan false negative memperjelas pola kesalahan model. Untuk kelas Negatif, true positive (TP) adalah 94 karena 94 data Negatif diprediksi Negatif. False positive (FP) Negatif adalah 11 karena 8 data Netral dan 3 data Positif salah masuk ke kelas Negatif. False negative (FN) Negatif adalah 0 karena tidak ada data Negatif yang diprediksi ke kelas lain. Untuk kelas Netral, TP = 0 dan FN = 8. Untuk kelas Positif, TP = 0 dan FN = 3.

TABLE XX. Analisis false positive dan false negative Naive Bayes

Kelas	TP	FP	FN	FPR*	FNR*
Negatif	94	11	0	10,48%	0,00%
Netral	0	0	8	0,00%	100,00%
Positif	0	0	3	0,00%	100,00%

*FPR pada tabel dihitung secara praktis sebagai FP/(FP+TP), sedangkan FNR dihitung sebagai FN/(FN+TP). Hasil ini menunjukkan bahwa kelas Netral dan Positif mengalami false negative rate 100%. Dengan kata lain, seluruh data testing yang seharusnya Netral dan Positif hilang ke prediksi Negatif.

Bagi penelitian opini publik, pola ini penting. Jika model digunakan tanpa membaca confusion matrix, peneliti dapat menyimpulkan bahwa sentimen publik hampir sepenuhnya negatif. Padahal, sebagian kecil data Netral dan Positif memang ada dalam manual label, tetapi tidak tertangkap oleh model. Oleh karena itu, evaluasi model harus selalu disertai pembacaan distribusi label dan kesalahan prediksi.

F. Pembahasan Diskursus Isu Ijazah Jokowi

Gabungan hasil relevansi, komposisi akun, sebaran term, manual label, KSI, dan Naive Bayes menunjukkan pola yang konsisten: diskursus isu ijazah Jokowi di Twitter/X sangat terpusat dan sangat negatif. Relevansi topik 99,5% menunjukkan dataset fokus. Dominasi akun individu 99% menunjukkan percakapan digerakkan terutama oleh pengguna personal. Term "ijazah", "jokowi", dan "palsu" menunjukkan inti isu. Manual label 89,7% Negatif menunjukkan polaritas dominan. KSI dan Naive Bayes juga sama-sama cenderung membaca dominasi Negatif.

Namun, pembacaan ini tidak boleh berhenti pada klaim bahwa semua percakapan adalah negatif. Data menunjukkan adanya 25 data Netral dan 11 data Positif pada manual label. KSI gagal mengenali Positif, dan Naive Bayes juga gagal mengenali Netral serta Positif pada testing set. Artinya, secara substantif ada variasi opini, tetapi secara model variasi itu tertutup oleh dominasi kelas Negatif.

Dari sisi sosial-politik, term "palsu" dan "asli" memperlihatkan pertarungan narasi kebenaran. Kata "ugm" menunjukkan rujukan institusional yang digunakan dalam debat. Kata "fitnah" mengindikasikan adanya narasi bantahan terhadap tuduhan. Dengan kata lain, percakapan bukan sekadar ekspresi kebencian, tetapi juga arena pembentukan legitimasi, pembelaan, tuduhan, dan penolakan.

Dominasi negatif dapat dimaknai sebagai tingginya intensitas ketidakpercayaan, kritik, atau kecurigaan publik digital pada topik tersebut. Namun, karena data berasal dari Twitter/X dan didominasi akun individu, hasil ini tidak dapat digeneralisasi langsung ke seluruh masyarakat Indonesia. Hasil lebih tepat dibaca sebagai potret diskursus digital pada dataset dan periode crawling yang digunakan.

G. Implikasi Metodologis

Penelitian ini memperlihatkan dua pelajaran metodologis. Pertama, data yang sangat timpang dapat membuat model terlihat baik secara accuracy tetapi buruk secara keseimbangan kelas. Accuracy 89,52% pada Naive Bayes terlihat tinggi, tetapi macro f1-score hanya 0,31. Kedua, pendekatan leksikon dan machine learning sama-sama memiliki keterbatasan ketika digunakan pada diskursus politik yang informal dan penuh konteks.

Karena itu, artikel ini menekankan pentingnya narasi evaluasi yang objektif: tidak cukup hanya melaporkan accuracy. Penelitian perlu menjelaskan confusion matrix, FP/FN, distribusi label, dan alasan mengapa model gagal membaca kelas minoritas. Dengan cara itu, hasil penelitian menjadi lebih jujur dan tidak menutupi kelemahan model.

V. KESIMPULAN DAN SARAN

A. Kesimpulan

Penelitian ini membangun pipeline analisis sentimen terhadap kontroversi isu ijazah Jokowi di Twitter/X menggunakan KSI dan Naive Bayes. Dari 1.000 tweet mentah, proses basic cleaning tidak menghapus baris data, sedangkan filter spam menghapus 21 data sehingga tersisa 979 tweet bersih. Preliminary analysis terhadap 200 data menunjukkan 199 tweet relevan dan 198 tweet berasal dari akun individu.

Analisis entropy dilakukan pada 200 data dengan total 3.608 kata dan 1.366 unique term. Output coding menghasilkan entropy total -2,628284 karena rumus yang digunakan menghitung p log10(p). Dalam pembacaan Shannon entropy, nilai tersebut menjadi 2,628284 setelah diberi tanda negatif. Term paling dominan adalah "ijazah", "jokowi", dan "palsu", yang menunjukkan bahwa dataset terpusat pada inti isu.

Pelabelan manual terhadap 350 data menunjukkan dominasi kelas Negatif sebesar 314 data atau 89,7%, disusul Netral 25 data atau 7,1%, dan Positif 11 data atau 3,1%. Validasi KSI terhadap manual label menghasilkan akurasi 82,29%, tetapi performa KSI tidak seimbang: kelas Negatif kuat, sedangkan kelas Positif gagal dikenali.

Naive Bayes memperoleh accuracy 89,52% pada 105 data testing. Namun, confusion matrix memperlihatkan bahwa semua data testing

diprediksi sebagai Negatif. Model benar pada 94 data Negatif, tetapi salah pada 8 data Netral dan 3 data Positif. Dengan demikian, accuracy tinggi dipengaruhi dominasi kelas Negatif dan belum menunjukkan kemampuan klasifikasi tiga kelas secara seimbang.

B. Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan. Pertama, manual label hanya mencakup 350 data dari 979 tweet bersih. Kedua, distribusi label sangat tidak seimbang sehingga model cenderung bias ke kelas mayoritas. Ketiga, pelabelan manual dilakukan berdasarkan satu skema anotasi sehingga belum ada pengukuran inter-annotator agreement. Keempat, KSI berbasis leksikon sulit membaca sarkasme, negasi kompleks, dan konteks politik. Kelima, entropy dihitung dari 200 sampel, sehingga interpretasinya menggambarkan sampel, bukan seluruh dataset.

Keterbatasan lainnya adalah model hanya menggunakan Naive Bayes. Model ini memang sesuai sebagai baseline, tetapi belum tentu optimal untuk data politik yang sangat tidak seimbang. Karena kelas Positif dan Netral sangat kecil, model gagal mempelajari pola fitur yang cukup kuat untuk membedakannya dari Negatif.

C. Saran Penelitian Lanjutan

Penelitian lanjutan disarankan memperluas manual label agar kelas Netral dan Positif memiliki jumlah yang lebih representatif. Selain itu, proses pelabelan sebaiknya melibatkan lebih dari satu anotator dan mengukur inter-annotator agreement seperti Cohen Kappa. Dari sisi modeling, penelitian lanjutan dapat mencoba Complement Naive Bayes, Logistic Regression, LinearSVC, atau model transformer berbahasa Indonesia, tetapi hanya setelah dataset berlabel lebih seimbang.

Dari sisi analisis sosial, penelitian lanjutan dapat membedakan opini berdasarkan tipe akun, waktu percakapan, atau jaringan interaksi. Topik isu ijazah Jokowi tidak hanya dapat dibaca sebagai sentimen positif-negatif, tetapi juga sebagai pertarungan narasi antara tuduhan, bantahan, legitimasi institusional, dan kepercayaan politik di ruang digital.

VI. URAIAN DETAIL BERDASARKAN URUTAN CODING

A. Cell Load Dataset dan Validasi Kolom

Notebook memulai proses dengan membaca file CSV menggunakan pandas. Dataset dibaca dengan separator koma dan fallback separator titik koma apabila pembacaan pertama gagal. Strategi ini penting karena file hasil crawling dapat memiliki struktur delimiter yang berbeda. Setelah file dibaca, notebook menggabungkan dataframe dan menampilkan daftar kolom. Output menunjukkan 1.000 baris dan 15 kolom. Kolom full_text menjadi pusat analisis karena berisi teks tweet. Kolom username dan tweet_url digunakan sebagai pelengkap audit, sedangkan kolom statistik seperti favorite_count, reply_count, dan retweet_count tidak digunakan langsung dalam modeling sentimen.

Secara metodologis, langkah validasi kolom mencegah kesalahan analisis. Jika model langsung berjalan tanpa memastikan kolom teks, maka preprocessing dapat diarahkan ke kolom yang salah. Dalam penelitian ini, pipeline sudah eksplisit karena teks berasal dari full_text, lalu disalin ke kolom yang diproses lebih lanjut. Hal ini membuat alur data dapat dilacak dari raw tweet hingga hasil prediksi.

TABLE XXI. Uraian tahap load dataset berdasarkan coding

Urutan coding	Output / tindakan	Fungsi metodologis
Read CSV	Loaded rows = 1.000	Membaca data crawling Twitter/X
Cek kolom	15 kolom terdeteksi	Memastikan struktur dataset benar
Ambil teks	full_text -> Clean_Text	Menentukan sumber analisis sentimen
Simpan metadata	username, tweet_url	Memudahkan audit dan pelacakan data

B. Cell Cleaning dan Dampaknya terhadap Data

Fungsi clean_text_basic mengubah teks menjadi lowercase, menghapus URL, mention, hashtag, karakter non-huruf, angka, dan spasi berlebih. Proses ini menghasilkan kolom Clean_Text. Output menunjukkan rows removed = 0. Artinya, meskipun simbol dan noise dibersihkan, seluruh tweet masih memiliki isi teks yang dapat dianalisis. Ini berbeda dengan filter spam yang memang menghapus baris.

Keputusan untuk menghapus mention dan URL tepat karena kedua elemen tersebut biasanya tidak membawa sentimen utama. Mention lebih berfungsi sebagai alamat percakapan, sedangkan URL lebih berfungsi sebagai rujukan eksternal. Namun, penghapusan hashtag juga perlu dibaca kritis. Pada sebagian kasus, hashtag dapat memuat sentimen. Dalam dataset ini, fokus utama term masih tertangkap melalui kata seperti ijazah, jokowi, dan palsu, sehingga penghapusan hashtag tidak terlihat menggeser inti topik.

TABLE XXII. Detail operasi basic cleaning

Operasi cleaning	Contoh efek	Risiko jika tidak dilakukan
Lowercase	Jokowi -> jokowi	Kata sama dianggap fitur berbeda
Hapus URL	https://... -> kosong	URL menjadi noise fitur
Hapus mention	@akun -> kosong	Nama akun mengganggu term utama
Hapus non-huruf	!!, angka, emoji -> kosong	Simbol ikut dihitung sebagai fitur
Rapikan spasi	spasi ganda -> spasi tunggal	Tokenisasi menjadi tidak konsisten

C. Cell Normalisasi Slang dan Negasi

Normalisasi slang dilakukan menggunakan kamus manual. Pada dataset politik Twitter/X, normalisasi tidak dapat dianggap tahap tambahan yang kecil. Banyak opini publik disampaikan menggunakan bahasa informal. Kata seperti gak, ga, nggak, tdk, dan tak harus disatukan menjadi tidak agar model membaca pola negasi secara konsisten. Jika tidak, kata-kata tersebut akan tersebar menjadi fitur terpisah dan bobot sentimen menjadi lemah.

Dalam isu ijazah Jokowi, negasi berperan penting karena banyak kalimat berisi bantahan atau tuduhan, misalnya "tidak palsu", "bukan palsu", "tidak asli", atau "tidak percaya". Dengan normalisasi, pola semacam ini lebih mungkin tertangkap oleh TF-IDF n-gram. Meski demikian, normalisasi saja belum cukup untuk memahami sarkasme atau ironi. Oleh karena itu, evaluasi model tetap harus dilakukan dengan manual label.

D. Cell Filter Spam

Filter spam dilakukan dengan mencocokkan teks terhadap daftar kata yang mengindikasikan promosi atau konten tidak relevan. Output menunjukkan 21 tweet dibuang. Secara proporsi, spam hanya 2,1% dari 1.000 data. Angka ini tidak besar, tetapi tetap penting karena konten promosi dapat mengganggu sebaran term. Jika kata seperti promo, diskon, voucher, atau skincare masuk ke korpus, visualisasi top term dapat kehilangan fokus pada isu ijazah Jokowi.

Setelah filter spam, dataset utama berjumlah 979 tweet. Angka ini menjadi dasar bagi proses labeling KSI penuh. Dengan demikian, angka 979 harus dibedakan dari angka 350. Angka 979 adalah dataset utama setelah filter spam, sedangkan 350 adalah subset yang dilabeli manual untuk supervised learning.

E. Cell Preliminary Analysis dan Maknanya

Notebook membuat dua file Excel untuk preliminary analysis: relevansi topik dan komposisi akun. Keduanya memakai 200 data. Relevansi topik memeriksa apakah tweet benar-benar membahas isu ijazah Jokowi. Komposisi akun memeriksa apakah percakapan berasal dari akun individu atau official/media resmi. Dua analisis ini penting karena sebelum membangun model, peneliti harus membuktikan bahwa dataset memang sesuai topik dan mengetahui karakter sumber percakapan.

Hasil 199 tweet relevan dari 200 menunjukkan keyword crawling sangat presisi. Hasil 198 akun individu dari 200 menunjukkan diskursus lebih bersifat organik dari pengguna publik. Kombinasi keduanya memperkuat argumentasi bahwa dataset bukan kumpulan berita media semata, melainkan percakapan pengguna Twitter/X tentang isu politik kontroversial.

TABLE XXIII. Makna preliminary analysis terhadap kualitas dataset

Aspek	Hasil	Makna dalam artikel
Relevansi topik	199/200 relevan	Dataset fokus pada isu ijazah Jokowi
Noise topik	1/200 tidak relevan	Gangguan topik sangat kecil
Akun individu	198/200	Diskursus didominasi opini publik langsung
Official/media	2/200	Narasi institusional tidak dominan

VII. PERHITUNGAN ENTROPY SECARA LEBIH RINCI

A. Perbedaan Entropy Coding dan Entropy Manual

Bagian ini ditambahkan karena output notebook menampilkan nilai entropy total negatif. Hal ini sering membingungkan. Dalam sheet term_entropy, kolom Nilai Entropy Term dihitung dengan rumus p x log10(p). Karena nilai p berada antara 0 dan 1, log10(p) selalu negatif. Akibatnya setiap kontribusi term menjadi negatif dan jumlah akhirnya juga negatif.

Dalam teori Shannon entropy, rumus yang umum digunakan adalah H = - sum p log(p). Tanda negatif diletakkan di depan penjumlahan agar nilai entropy menjadi positif. Jadi, ketika coding menghasilkan -2,628284, nilai tersebut bukan kesalahan data. Nilai itu adalah bentuk tanpa tanda negatif. Jika dibaca dengan konvensi Shannon, entropy menjadi 2,628284.

Coding total = sum p_i log10(p_i) = -2.628284

Manual Shannon total = -1 x (-2.628284) = 2.628284

Dengan demikian, artikel perlu menarasikan keduanya secara eksplisit. Output coding tetap dilaporkan sebagai -2,628284 karena itu yang muncul di notebook. Namun, interpretasi konseptual entropy dilakukan dengan nilai positif 2,628284.

B. Perhitungan Detail Top 10 Term

TABLE XXIV. Perhitungan entropy manual untuk 10 term teratas

Term	Ni	p	log10(p)	Coding p log10(p)	Manual -p log10(p)
ijazah	274	0,075942	-1,119516	-0,085019	0,085019
jokowi	237	0,065687	-1,182518	-0,077676	0,077676
palsu	235	0,065133	-1,186199	-0,077261	0,077261
tidak	86	0,023836	-1,622768	-0,038680	0,038680
asli	50	0,013858	-1,858297	-0,025752	0,025752
ugm	37	0,010255	-1,989065	-0,020398	0,020398
kasus	32	0,008869	-2,052117	-0,018201	0,018201
orang	27	0,007483	-2,125903	-0,015909	0,015909
pak	24	0,006652	-2,177021	-0,014482	0,014482
termul	23	0,006375	-2,195520	-0,013997	0,013997

Tabel XXIV menunjukkan bahwa kontribusi entropy terbesar berasal dari term paling sering muncul, terutama ijazah, jokowi, dan palsu. Ketiga kata ini tidak hanya sering muncul, tetapi juga memegang fungsi tema utama. Besarnya kontribusi entropy pada term ini memperlihatkan bahwa topik dataset sangat terpusat pada isu inti. Namun, unique term yang mencapai 1.366 menunjukkan bahwa percakapan tetap memiliki variasi kosakata yang luas.

C. Interpretasi Normalized Entropy

Jika unique term sebanyak 1.366 digunakan sebagai jumlah kategori kosakata, maka entropy maksimum berbasis log10 adalah log10(1366) = 3,13545. Nilai entropy konvensional 2,628284 menghasilkan normalized entropy sekitar 0,838. Angka ini menunjukkan bahwa distribusi term tidak sepenuhnya terkonsentrasi pada satu kata, tetapi juga tidak sepenuhnya merata. Ada dominasi topik yang jelas, disertai variasi kata yang masih besar.

H_max = log10(1366) = 3.13545

Normalized H = 2.628284 / 3.13545 = 0.838

Interpretasi tersebut konsisten dengan visualisasi Top 20 term. Kata ijazah, jokowi, dan palsu menjadi puncak frekuensi, tetapi setelah itu masih muncul kata seperti tidak, asli, ugm, kasus, orang, pak, termul, indonesia, presiden, fitnah, dan bukan. Variasi ini memperlihatkan bahwa percakapan tidak hanya mengulang keyword, tetapi memuat bantahan, tuduhan, rujukan institusi, dan framing politik.

VIII. PERHITUNGAN MANUAL NAIVE BAYES DAN EVALUASI MODEL

A. Dari Distribusi Label ke Prior Kelas

Perhitungan algoritma dimulai dari distribusi label training. Karena split menggunakan stratify, proporsi label pada training mengikuti distribusi keseluruhan. Dari 245 data training, terdapat 220 Negatif, 17 Netral, dan 8 Positif. Prior kelas menunjukkan peluang awal model sebelum melihat fitur teks.

P(Negatif) = 220 / 245 = 0.89796

P(Netral) = 17 / 245 = 0.06939

P(Positif) = 8 / 245 = 0.03265

Prior Negatif yang sangat besar membuat model memiliki kecenderungan awal ke kelas Negatif. Hal ini bukan bug, melainkan konsekuensi matematika dari distribusi data. Jika fitur teks pada kelas minoritas tidak cukup kuat, model akan tetap memilih Negatif karena skor posteriornya lebih besar.

B. Dari TF-IDF ke Likelihood

Setelah teks diubah ke TF-IDF, setiap dokumen menjadi vektor fitur. Misalnya, satu tweet dapat memiliki fitur ijazah, jokowi, palsu, kasus, dan bigram seperti ijazah palsu. Nilai TF-IDF tiap fitur menjadi bobot x_i. Naive Bayes menghitung kontribusi fitur dengan mengalikan bobot x_i dengan log probabilitas fitur pada tiap kelas.

score(c,d) = log P(c) + x_1 log P(t_1|c) + x_2 log P(t_2|c) + ... + x_n log P(t_n|c)

Pada output contoh yang dihitung ulang dari notebook, sebuah dokumen berlabel manual Netral diprediksi sebagai Negatif. Hal ini terjadi karena total log-score kelas Negatif lebih besar daripada Netral dan Positif. Perhitungan ini memperlihatkan secara teknis bagaimana bias kelas mayoritas muncul dalam prediksi.

C. Mengapa Semua Data Testing Diprediksi Negatif

Confusion matrix menunjukkan seluruh testing set diprediksi sebagai Negatif. Penyebab utamanya adalah kombinasi antara distribusi training yang sangat timpang dan fitur-fitur topik yang sering muncul di kelas Negatif. Karena 220 dari 245 data training adalah Negatif, model banyak belajar bahwa kata-kata diskursus ijazah palsu cenderung berkaitan dengan kelas Negatif. Ketika menemukan data Netral atau Positif yang juga mengandung kata-kata topik seperti ijazah, jokowi, palsu, ugm, atau kasus, model tetap lebih sering mengarah ke Negatif.

Ini menjelaskan mengapa accuracy tinggi tidak boleh langsung dianggap sukses. Model berhasil pada kelas mayoritas karena mayoritas testing set juga Negatif. Tetapi model gagal secara konseptual untuk tugas klasifikasi tiga kelas karena tidak menghasilkan prediksi Netral dan Positif. Dalam laporan ilmiah, kondisi seperti ini harus dijelaskan secara terbuka agar pembaca memahami keterbatasan model.

D. Perhitungan Precision, Recall, dan F1-Score

Untuk kelas Negatif, model memiliki TP = 94, FP = 11, dan FN = 0. Precision Negatif dihitung sebagai TP/(TP+FP) = 94/(94+11) = 0,895 atau dibulatkan 0,90. Recall Negatif dihitung sebagai TP/(TP+FN) = 94/(94+0) = 1,00. F1-score Negatif dihitung sebagai 2 x precision x recall / (precision + recall), yaitu sekitar 0,94.

Precision_Negatif = 94 / (94 + 11) = 0.895

Recall_Negatif = 94 / (94 + 0) = 1.000

F1_Negatif = 2 x 0.895 x 1.000 / (0.895 + 1.000) = 0.944

Untuk kelas Netral, TP = 0 dan FN = 8. Karena model tidak pernah memprediksi Netral, precision dan recall menjadi 0. Untuk kelas Positif, TP = 0 dan FN = 3, sehingga precision, recall, dan f1-score juga 0. Macro f1-score rendah karena macro average menghitung rata-rata antar kelas tanpa mempertimbangkan dominasi jumlah data.

TABLE XXV. Perhitungan manual metrik evaluasi Naive Bayes

Kelas	TP	FP	FN	Precision	Recall	F1
Negatif	94	11	0	94/(94+11)=0,90	94/(94+0)=1,00	0,94
Netral	0	0	8	0,00	0,00	0,00
Positif	0	0	3	0,00	0,00	0,00

Tabel XXV menjelaskan bagaimana angka classification report terbentuk. Dengan demikian, pembahasan model tidak hanya

melaporkan output coding, tetapi juga menunjukkan proses matematis di balik precision, recall, dan f1-score.

REFERENCES

[1] M. Wankhade, A. C. S. Rao, and C. Kulkarni, "A survey on sentiment analysis methods, applications, and challenges," Artificial Intelligence Review, 2022.

[2] F. Koto and A. Rahmaningtyas, "InSet Lexicon: Evaluation of a Word List for Indonesian Sentiment Analysis in Microblogs," IEEE IALP, 2017.

[3] M. Rakhmadian et al., "Lexicon Addition Effect on Lexicon-Based of Indonesian Sentiment Analysis on Twitter," IEEE ICOIACT, 2021.

[4] J. D. M. Rennie, L. Shih, J. Teevan, and D. Karger, "Tackling the Poor Assumptions of Naive Bayes Text Classifiers," ICML, 2003.

[5] L. Geni, E. Yulianti, and D. I. Sensuse, "Sentiment Analysis of Tweets Before the 2024 Elections in Indonesia Using BERT Language Models," JITEKI, 2023.

[6] M. Q. Huzyan Octava et al., "Web-based Sentiment Analysis System Using SVM and TF-IDF with Statistical Feature," IEEE 3ICT, 2024.