Laporan Proyek UAS

Laporan Ekstraksi Bencana Banjir di Sumatera dari Data Twitter/X

Nama: Muhammad Ariefsyah

NIM: 2411502194

Teknik Informatika

Fakultas Teknologi Informasi

Universitas Budi Luhur

2026

1. Latar Belakang

Perkembangan teknologi informasi dan tingginya penggunaan media sosial di Indonesia telah menjadikan platform seperti Twitter/X sebagai sumber informasi yang penting dalam berbagai peristiwa aktual, termasuk bencana alam. Masyarakat secara aktif membagikan informasi, laporan kejadian, serta dampak bencana secara real time. Kondisi ini menghasilkan data teks dalam jumlah besar yang berpotensi dimanfaatkan untuk analisis kebencanaan, namun bersifat tidak terstruktur dan bervariasi secara linguistik.

Banjir merupakan salah satu bencana yang paling sering terjadi di wilayah Sumatera dan menimbulkan dampak signifikan terhadap masyarakat. Informasi terkait waktu kejadian, lokasi terdampak, penyebab, dan jumlah korban sering muncul dalam percakapan publik di media sosial, tetapi tidak tersaji dalam format yang sistematis. Oleh karena itu, diperlukan pendekatan pemrosesan bahasa alami (Natural Language Processing/NLP) untuk mengekstraksi informasi penting tersebut secara otomatis dan terstruktur.

Dalam proyek ini, digunakan pendekatan **rule-based NLP** dengan membangun pipeline yang terdiri dari tahapan **Scanner, Parser, Translator, dan Evaluator**. Data dikumpulkan melalui proses crawling Twitter/X menggunakan Tweet Harvest dengan kata kunci terkait banjir di wilayah Sumatera pada periode 1 November hingga 31 Desember 2025, menghasilkan 600 tweet berbahasa Indonesia. Pipeline ini dirancang untuk mengekstraksi dan menstandarkan informasi kebencanaan, sehingga hasilnya dapat digunakan sebagai dasar analisis, pelaporan, dan visualisasi data bencana secara lebih sistematis.

Tujuan Proyek:

1. Membangun pipeline pemrosesan bahasa alami berbasis aturan (rule-based NLP) yang terdiri dari tahap **Scanner, Parser, Translator, dan Evaluator** untuk mengekstraksi informasi kebencanaan banjir dari data Twitter/X.
2. Mengekstraksi informasi utama secara terstruktur, meliputi **waktu kejadian, lokasi administratif, jenis bencana, penyebab banjir, serta jumlah korban** dari teks tweet berbahasa Indonesia.
3. Menstandarkan istilah dan format data hasil ekstraksi agar konsisten dan siap digunakan dalam bentuk tabel terstruktur serta visualisasi dashboard.

4. Melakukan evaluasi kualitas hasil ekstraksi berdasarkan tingkat keterisian (coverage), validitas data, dan potensi noise untuk menilai keandalan pipeline yang dibangun.

2. Pipeline

a) Scanner:

Tahap Scanner pada proyek ini berfungsi untuk mengubah teks mentah tweet menjadi representasi linguistik dasar yang siap diproses pada tahap berikutnya. Seluruh proses pada tahap ini tidak melakukan ekstraksi makna, melainkan hanya melakukan pembersihan dan segmentasi teks.

1. Preprocessing Teks

Proses preprocessing direalisasikan melalui fungsi clean_text_inner.
Fungsi ini menerima teks tweet mentah dan melakukan pembersihan sebagai berikut:

- Menghapus URL menggunakan ekspresi reguler http\S+|www\.\S+
- Menghapus mention pengguna Twitter dengan pola @\w+
- Menghilangkan tanda pagar (#) tanpa menghapus kata setelahnya
- Menghapus emoji dan simbol non-linguistik dengan mempertahankan huruf, angka, spasi, serta simbol waktu
- Menghapus spasi berlebih agar teks menjadi rapi dan konsisten

Hasil preprocessing disimpan ke dalam kolom clean_text.
Pada tahap ini, teks masih berupa kalimat, tetapi sudah bebas dari noise khas media sosial.

2. Tokenisasi

Setelah preprocessing, teks bersih diproses menggunakan fungsi tokenize_inner.
Tokenisasi dilakukan dengan pendekatan berbasis regular expression, bukan tokenisasi standar library.
Pola tokenisasi dirancang secara eksplisit untuk:

- mempertahankan jam (misalnya 06:15, 14.30) sebagai satu token,
- mempertahankan angka korban sebagai satu token,
- memisahkan kata alfabet dan simbol penting.

Hasil tokenisasi disimpan dalam kolom tokens.
Output tahap ini berupa daftar token berurutan tanpa informasi makna.

3. POS Tagging Heuristik
Setelah tokenisasi, dilakukan pelabelan POS sederhana menggunakan fungsi simple_pos_tag.
POS tagging pada tahap ini bersifat heuristik, bukan linguistik penuh.
Aturan yang digunakan adalah:

- token yang diawali angka diberi label NUM,
- token yang diawali huruf kapital (bukan token pertama) diberi label NNP,
- token lainnya diberi label X.

Hasil POS tagging disimpan dalam kolom pos_tags.
Label ini digunakan sebagai fitur bantu pada tahap parsing, bukan sebagai analisis sintaksis.

4. Normalisasi Morfologi Ringan
Normalisasi morfologi diimplementasikan melalui fungsi normalize_morph.
Fungsi ini tidak menggantikan token asli, tetapi menghasilkan bentuk bantu untuk pencocokan aturan.
Normalisasi dilakukan dengan:

- menghapus awalan umum seperti ke-, se-, ber-, ter-,
- menghapus akhiran umum seperti -nya, -lah, -kah.

Hasil normalisasi disimpan dalam kolom tokens_norm.
Token asli tetap dipertahankan dan tidak diubah.

b) Parser:

Tahap **Parser** pada proyek ini adalah bagian kode yang **memberikan makna semantik** pada token hasil Scanner menggunakan aturan dan kamus.

Parser diimplementasikan melalui beberapa komponen utama:

1. **Leksikon dan Gazetteer**

   Parser mendefinisikan kamus eksplisit seperti:

   a. `DISASTER_LEX` untuk jenis bencana,
   b. `CAUSE_LEX` untuk penyebab banjir,
   c. `GEO_GAZETTEER` untuk lokasi wilayah Sumatera,
   d. kamus korban (`DEATH_WORDS`, `INJURY_WORDS`, `AFFECTED_WORDS`, `UNIT_WORDS`),
   e. pola waktu (`TIME_PATTERNS`).

Seluruh kamus ini digunakan langsung dalam proses parsing, bukan sebagai referensi konseptual.

2. **BIO Tagging (`tag_tokens_inner`)**

   Fungsi ini adalah **inti Parser**.

   Di dalamnya, token diberi label BIO berdasarkan:

   a. kecocokan leksikon,
   b. konteks sekitar token (window-based),
   c. aturan posisi (misalnya `di <lokasi>`, angka + unit korban).

Hasilnya adalah label seperti:

   d. `B-LOC`, `I-LOC`
   e. `B-DISASTER`
   f. `B-CAUSE`
   g. `B-TIME`
   h. `B-VICTIM-DEATH`, dll.

3. **Entity Extraction (`extract_entities`)**

   Kode ini menggabungkan token bertag BIO menjadi entitas utuh, misalnya:

   a. lokasi administratif,
   b. waktu kejadian,
   c. jenis banjir,
   d. penyebab,
   e. korban.

Output Parser disimpan dalam kolom:

- `location_extracted`
- `time_extracted`
- `disaster_extracted`
- `cause_extracted`
- `korban_terdampak`
- `korban_luka`
- `korban_meninggal`

c) Tahap **Translator** adalah bagian kode yang **mengonversi hasil Parser menjadi data terstruktur dan konsisten**.

d) Translator pada proyek ini diimplementasikan melalui:

e) **Normalisasi waktu**

Kode mendeteksi berbagai kolom waktu (`created_at`, `timestamp`, `parsed_time`) lalu mengonversinya ke format datetime tunggal (`tweet_time`).

f) **Normalisasi label jenis bencana (`clean_disaster_value`)**

Berbagai ekspresi seperti *banjir*, *kebanjiran*, *banjir rob*, dan *banjir bandang* diseragamkan ke label final.

g) **Kanonisasi lokasi administratif**

Blok *Cleanup Lokasi Admin* menggunakan:

a) gazetteer,
b) blacklist,
c) heuristik pengurangan noise,

untuk memastikan lokasi tidak berupa kalimat bebas atau istilah agregat.

h) **Penyamaan istilah penyebab bencana (`proses_penyebab_lengkap`)**

Istilah penyebab yang bervariasi dipetakan ke kategori standar seperti:

a) Curah Hujan Tinggi
b) Masalah Infrastruktur
c) Luapan Sungai

d) Masalah Lingkungan

i) **Pemetaan ke tabel akhir (`table_final`)**

Seluruh hasil diterjemahkan ke kolom final:

a) Waktu
b) Lokasi
c) Jenis_Bencana
d) Penyebab
e) Korban_Terdampak
f) Korban_Luka
g) Korban_Meninggal

d) Evaluator

```
=== LAPORAN EVALUASI KUALITAS DATA (ADVANCED) ===
```

	Atribut	Total Data	Terisi	Coverage (%)	Valid (Quality)	Valid (%)	Noise (Error)
0	Waktu	600	600	100.0	600	100.0	0
1	Lokasi	600	184	30.7	184	30.7	0
2	Jenis_Bencana	600	583	97.2	583	97.2	0
3	Penyebab	600	15	2.5	15	2.5	0
4	Korban_Terdampak	600	1	0.2	1	0.2	0
5	Korban_Luka	600	0	0.0	0	0.0	0
6	Korban_Meninggal	600	3	0.5	3	0.5	0

```
[INSPEKSI] Sampel Data 'Noise' pada Kolom Korban (Jika Ada):
-> Tidak ditemukan noise pada kolom Korban Terdampak (Data bersih).
```

```
[INSPEKSI] Data Tanpa Lokasi:
```

	Waktu	Lokasi	Jenis_Bencana	Penyebab	Korban_Terdampak	Korban_Luka	Korban_Meninggal
1	2025-12-30 16:23:50		Banjir				
2	2025-12-30 15:55:18		Banjir				
4	2025-12-30 15:38:25		Banjir	Masalah Lingkungan			
5	2025-12-30 15:37:00		Banjir				
6	2025-12-30 15:36:04		Banjir				

```
Jenis_Bencana
Banjir    583
          17
dtype: int64
```

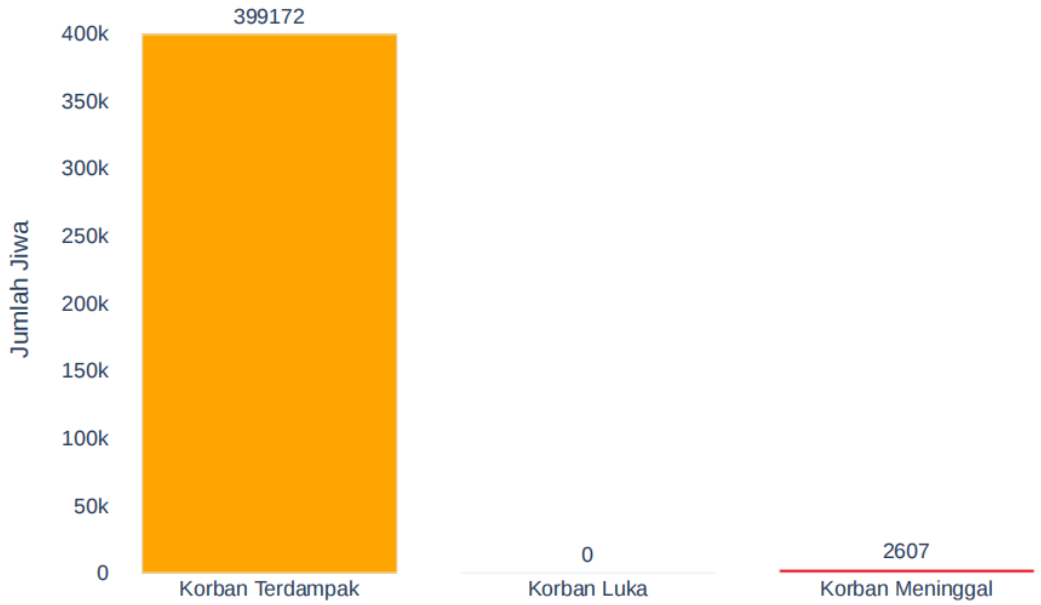
3. Hasil

Proyek ini menganalisis **600 tweet Twitter/X** terkait banjir di wilayah **Sumatera** pada periode **1 November–31 Desember 2025** menggunakan pipeline **Scanner–Parser–Translator–Evaluator** berbasis aturan. Hasil menunjukkan bahwa **informasi waktu** dan **jenis bencana** merupakan atribut yang paling konsisten diekstraksi, dengan tingkat keterisian mendekati penuh, karena didukung oleh metadata dan kata kunci eksplisit dalam teks. **Jenis bencana** yang teridentifikasi didominasi oleh kategori *banjir*, termasuk variasinya seperti banjir bandang dan banjir rob.

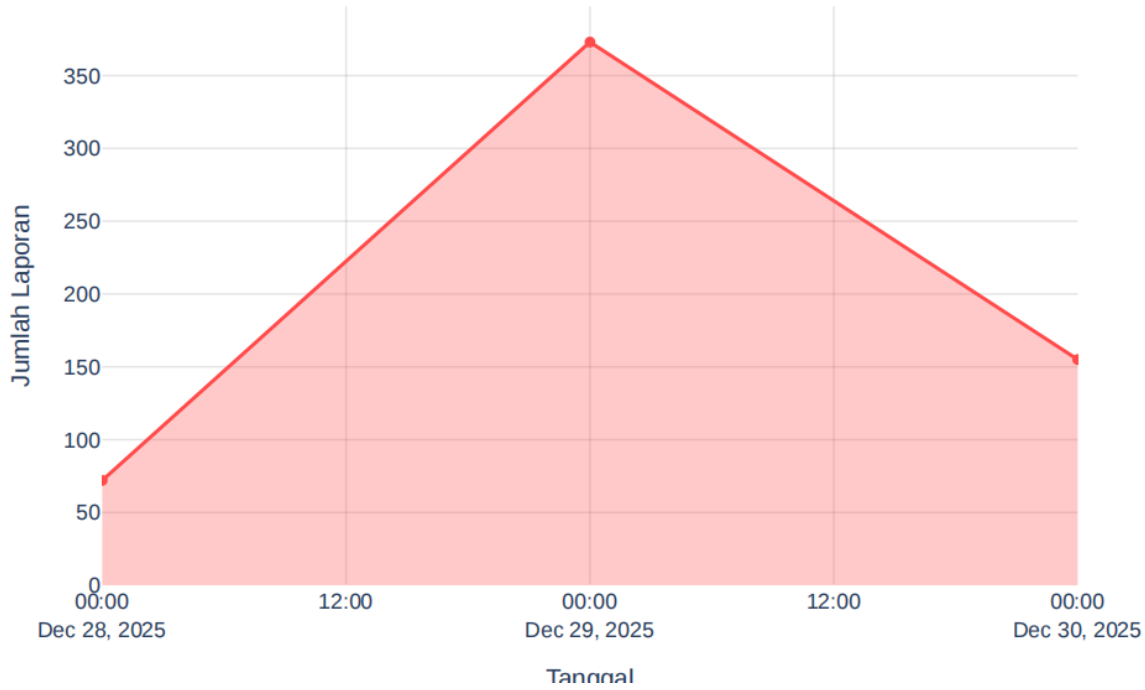
Sebaliknya, **lokasi administratif**, **penyebab bencana**, dan **data korban** memiliki tingkat keterisian yang lebih rendah. Lokasi hanya berhasil diekstraksi ketika wilayah disebutkan secara eksplisit, sedangkan penyebab dan korban jarang muncul karena sebagian besar tweet bersifat laporan singkat atau reaksi tanpa detail faktual. Sistem secara sengaja tidak melakukan inferensi atau penebakan, sehingga angka tanpa konteks dan satuan manusia tidak diklasifikasikan sebagai data korban. Secara keseluruhan, hasil ini menunjukkan bahwa pendekatan rule-based yang digunakan menghasilkan **ekstraksi yang presisi**, meskipun dengan **cakupan terbatas**, dan mencerminkan karakteristik informasi bencana yang disampaikan pengguna media sosial.

Grafik Visualisasi

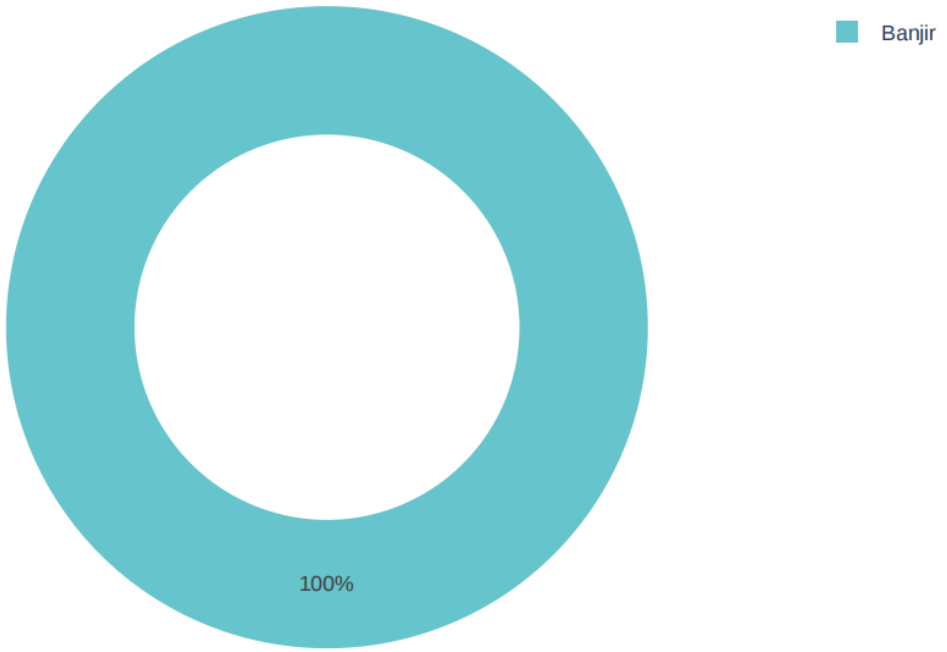
Statistik Dampak Korban



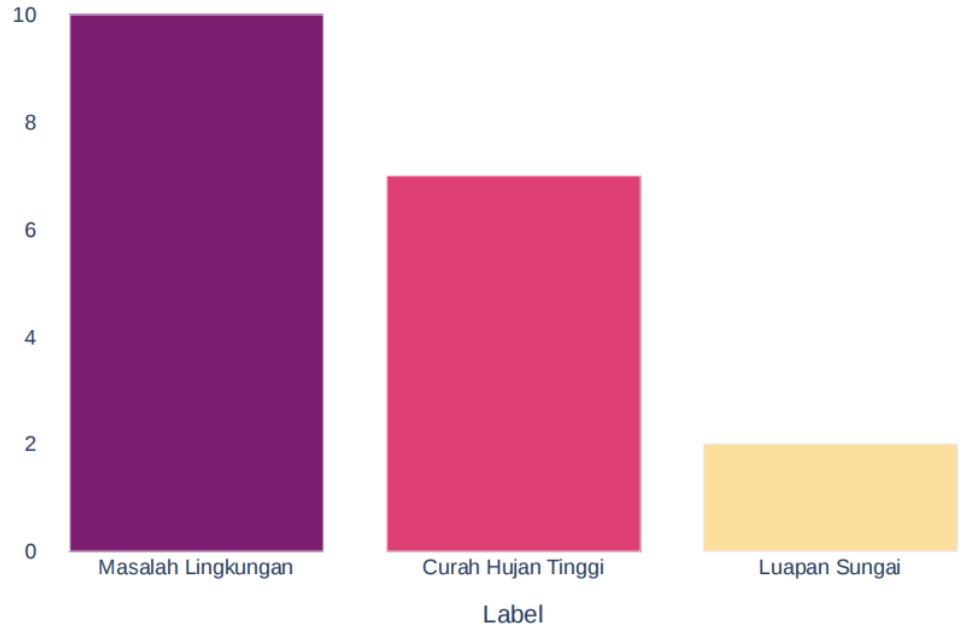
Tren Waktu

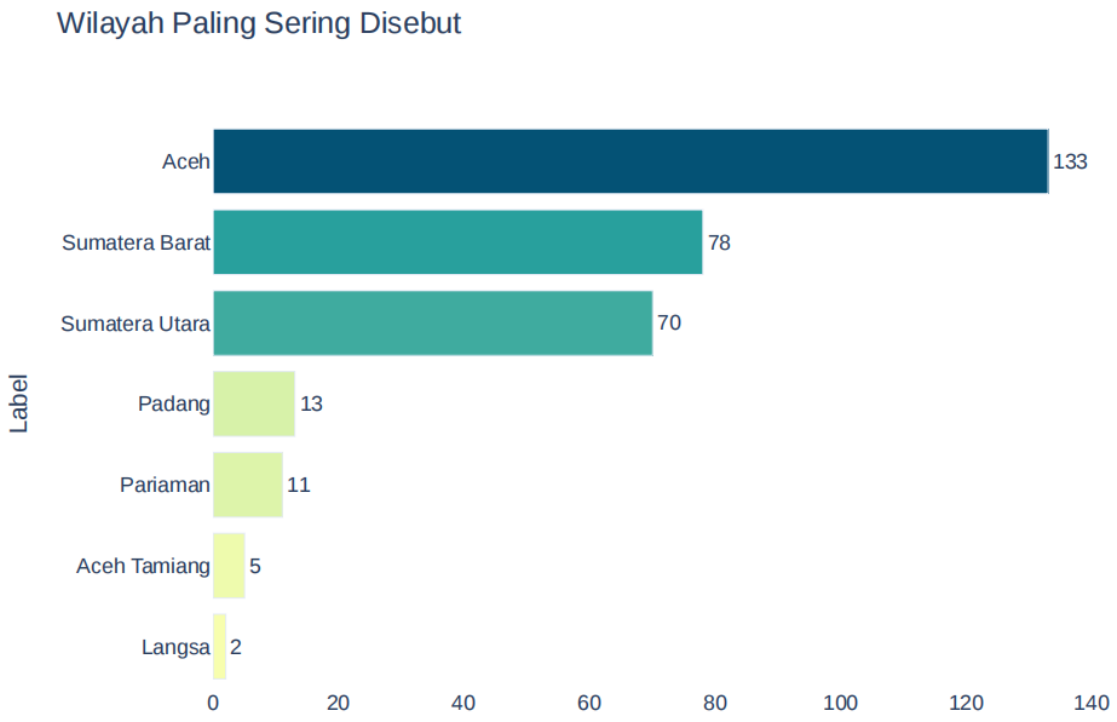


Komposisi Jenis Bencana



Faktor Penyebab Dominan




Wilayah Paling Sering Disebut
Label
Aceh
Sumatera Barat
Sumatera Utara
Padang
Pariaman
Aceh Tamiang
Langsa
133
78
70
13
11
5
2
0
20
40
60
80
100
120
140